

**Pró-Reitoria Acadêmica
Curso de Engenharia de Software**

Trabalho Final – Academic Dropout Risk, Fuzzy

**Autores: João Pedro Nunes Neto
Leonardo dos Santos Silva
Lucas Gabriel Pereira Guerra
Luís Felipe Nunes Neto
Luiz Phillipe de Souza Santos**

Orientador: William Roberto Malvezzi

João Pedro Nunes Neto
Leonardo dos Santos Silva
Lucas Gabriel Pereira Guerra
Luís Felipe Nunes Neto
Luiz Phillipe de Souza Santos

Trabalho Final – Academic Dropout Risk, Fuzzy

Relatório técnico apresentado como requisito avaliativo da disciplina de Inteligência Artificial – AT2 N2, do Curso de Engenharia de Software da Universidade Católica de Brasília.

Orientador: Prof. William Roberto Malvezzi

Brasília – DF

2026

RESUMO

Este trabalho apresenta o desenvolvimento de um pipeline completo de classificação supervisionada aplicado a um conjunto sintético de dados, que permite emular a situação acadêmica sem precisar inferir dados que poderiam ferir a LGPD, com o objetivo principal do sistema sendo prever através de históricos e padrões acadêmicos, o risco de evasão acadêmica, permitindo assim que haja intervenção pelos pedagogos de forma prévia. O sistema foi desenvolvido utilizando dois sistemas de machine learning, Árvore de decisão, e Naive Bayes gaussiano. No sistema principal, a Árvore de Decisão atingiu acurácia média de 84,1%, enquanto o Naive Bayes atingiu acurácia de 92,1%. Além dos scores de machine learning, foi utilizada a inferência baseada em Fuzzy para melhor estudar a correlação dos dados com o resultado obtido. O trabalho demonstrou a importância de utilização de sistemas de inferência para avaliação de resultados, além da correlação entre a interação acadêmica e o risco de evasão.

Palavras-chave: machine learning; classificação supervisionada; Fuzzy; Árvore de decisão; Naive Bayes Gaussiano.

SUMÁRIO

1 INTRODUÇÃO.....	7
2 OBJETIVOS.....	7
2.1 Objetivo Geral	7
2.2 Objetivos Específicos	7
3 FUNDAMENTAÇÃO TEÓRICA	8
3.1 Inteligência Artificial.....	8
3.2 Machine Learning.....	8
3.3 Classificação Supervisionada	8
3.4 Árvore de Decisão	8
3.5 Naive Bayes Gaussiano	8
3.6 Lógica Fuzzy	8
3.7 Conjuntos Fuzzy	9
3.8 Variáveis Linguísticas	9
3.9 Funções de Pertinência	9
3.10 Sistema de Inferência Mamdani	9
4 DESCRIÇÃO DO DATASET	10
5 ANÁLISE EXPLORATÓRIA DOS DADOS (EDA).....	10
6 PRÉ-PROCESSAMENTO DOS DADOS	12
6.1 Codificação do Alvo.....	13
6.2 Normalização.....	13
6.3 Divisão.....	13
7 MODELAGEM	13
7.1 Estratégia de Avaliação	13
7.2 Primeiro Modelo – Árvore de Decisão.....	13
7.3 Segundo Modelo – Naive Bayes Gaussiano.....	16
8 SISTEMA DE INFERÊNCIA FUZZY	17
9 INTEGRAÇÃO E COMPARAÇÃO	18
10 RESULTADOS E DISCUSSÃO	19

11 LIMITAÇÕES DO TRABALHO	20
12 POSSÍVEIS MELHORIAS	20
13 CONCLUSÃO.....	20
14 BIBLIOTECAS UTILIZADAS	21
REFERÊNCIAS	22

1. INTRODUÇÃO

A evasão acadêmica representa um dos principais desafios enfrentados pelas instituições de ensino superior. Além dos impactos financeiros e administrativos para as universidades, a interrupção dos estudos pode comprometer o desenvolvimento profissional e pessoal dos estudantes. Dessa forma, a identificação precoce de fatores associados ao risco de evasão torna-se uma ferramenta importante para que coordenadores, pedagogos e gestores educacionais possam implementar ações preventivas e estratégias de acompanhamento individualizado.

Nos últimos anos, técnicas de Inteligência Artificial têm sido amplamente utilizadas para apoiar processos de tomada de decisão em diferentes áreas, incluindo a educação. Entre essas técnicas, destacam-se os métodos de Machine Learning, capazes de identificar padrões ocultos em grandes volumes de dados e gerar previsões com elevado grau de precisão. No contexto acadêmico, tais métodos podem auxiliar na identificação de estudantes com maior probabilidade de abandonar seus cursos, permitindo intervenções antecipadas.

Entretanto, modelos puramente estatísticos nem sempre fornecem interpretações suficientemente claras para especialistas humanos. Nesse cenário, a Lógica Fuzzy surge como uma alternativa complementar, pois permite representar conceitos subjetivos e graduais, como baixo engajamento, frequência média ou risco elevado, por meio de variáveis linguísticas e regras interpretáveis. Dessa forma, a combinação entre Machine Learning e sistemas fuzzy possibilita unir desempenho preditivo e interpretabilidade.

Devido às restrições relacionadas à privacidade e à proteção de dados pessoais previstas pela Lei Geral de Proteção de Dados (LGPD), optou-se pela utilização de uma base de dados sintética. Essa abordagem permite reproduzir cenários acadêmicos realistas sem expor informações sensíveis de estudantes reais, possibilitando o desenvolvimento e a validação da metodologia proposta de forma ética e segura.

Neste trabalho foi adotada uma abordagem híbrida, denominada Abordagem B, na qual um modelo de Machine Learning é inicialmente utilizado para estimar probabilidades de evasão. Posteriormente, essas probabilidades são utilizadas como entrada para um sistema de inferência fuzzy baseado no método de Mamdani, responsável por produzir uma classificação interpretável do risco acadêmico. O objetivo principal consiste em desenvolver e avaliar um sistema capaz de identificar estudantes com diferentes níveis de risco de evasão, explorando a complementaridade entre modelos probabilísticos e sistemas de inferência fuzzy.

2. OBJETIVOS

2.1 Objetivo Geral

Desenvolver um sistema de machine learning supervisionado para a detecção de risco de evasão acadêmica, utilizando Inferência Fuzzy.

2.2 Objetivos Específicos

- compreender a estrutura do problema de classificação de risco de evasão acadêmica;
- explorar os dados e identificar padrões relevantes por meio de análise exploratória (EDA);
- realizar pré-processamento dos dados, incluindo codificação do alvo, normalização e divisão estratégica;
- comparar os algoritmos Árvore de Decisão e Naive Bayes Gaussiano com validação cruzada;
- implementar um sistema de inferência Fuzzy (método Mamdani) com variáveis linguísticas e regras bem fundamentadas;
- integrar o melhor modelo de ML ao pipeline Fuzzy (Abordagem B), alimentando o sistema com probabilidades

geradas pelo Naive Bayes;
analisar a coerência e complementaridade entre as predições do ML e os rótulos gerados pelo Fuzzy.

3. FUNDAMENTAÇÃO TEÓRICA

3.1 Inteligência Artificial

A Inteligência Artificial (IA) consiste em um campo da ciência da computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam inteligência humana, tais como reconhecimento de padrões, tomada de decisão, aprendizado e resolução de problemas. Segundo Russell e Norvig (2013), a IA busca construir agentes capazes de perceber o ambiente e agir racionalmente para atingir objetivos específicos.

3.2 Machine Learning

Machine Learning é uma subárea da Inteligência Artificial que permite aos sistemas aprender padrões a partir de dados sem a necessidade de programação explícita para cada situação. Em vez de seguir regras previamente definidas, os algoritmos analisam exemplos históricos e constroem modelos capazes de realizar previsões sobre novos dados.

Entre os principais paradigmas de aprendizado estão o aprendizado supervisionado, não supervisionado e por reforço. Neste trabalho foi utilizado o aprendizado supervisionado, no qual os modelos são treinados a partir de exemplos previamente rotulados.

3.3 Classificação Supervisionada

A classificação supervisionada consiste em prever a categoria à qual uma determinada observação pertence. Nesse tipo de problema, cada registro possui um conjunto de atributos de entrada e uma classe conhecida utilizada durante o treinamento.

No contexto deste projeto, o problema foi modelado como uma classificação multiclasse, em que os estudantes são classificados em três categorias de risco de evasão: baixo, médio e alto.

3.4 Árvore de Decisão

As Árvores de Decisão são algoritmos de classificação que organizam o processo de decisão em uma estrutura hierárquica composta por nós e ramificações. Cada nó representa uma condição aplicada a um atributo, enquanto as folhas representam a classe prevista.

Uma das principais vantagens desse algoritmo é sua interpretabilidade, permitindo compreender quais variáveis influenciam as decisões do modelo. Para selecionar as divisões mais adequadas, foi utilizado o índice de impureza de Gini, amplamente empregado em problemas de classificação.

3.5 Naive Bayes Gaussiano

O algoritmo Naive Bayes é um classificador probabilístico baseado no Teorema de Bayes. Sua principal característica é assumir independência condicional entre os atributos, simplificando significativamente os cálculos necessários para estimar probabilidades.

A variante Gaussiana foi utilizada neste trabalho por ser adequada para variáveis numéricas contínuas. Apesar de sua simplicidade matemática, o algoritmo frequentemente apresenta resultados competitivos em diferentes problemas de classificação.

3.6 Lógica Fuzzy

A Lógica Fuzzy foi proposta por Lotfi Zadeh em 1965 com o objetivo de representar situações em que os limites entre verdadeiro e falso não são perfeitamente definidos. Diferentemente da lógica clássica, que trabalha apenas com os valores 0 e 1, a lógica fuzzy permite graus intermediários de pertencimento.

Essa característica torna a abordagem particularmente adequada para problemas que envolvem conceitos subjetivos, como desempenho acadêmico, engajamento estudantil e risco de evasão.

3.7 Conjuntos Fuzzy

Um conjunto fuzzy é definido por uma função de pertinência $\mu(x)$, responsável por atribuir a cada elemento um grau de pertencimento compreendido entre 0 e 1.

Por exemplo, um estudante com frequência de 55% pode pertencer parcialmente ao conjunto "frequência baixa" e simultaneamente ao conjunto "frequência média". Essa capacidade de representar transições graduais constitui uma das principais vantagens da lógica fuzzy.

3.8 Variáveis Linguísticas

Variáveis linguísticas são variáveis cujos valores são expressos por termos da linguagem natural. Em vez de utilizar apenas valores numéricos, a lógica fuzzy permite representar conceitos por rótulos linguísticos.

Neste trabalho foram utilizadas variáveis como:

- Probabilidade de evasão: baixa, média e alta;
- Frequência: baixa, média e alta;
- Engajamento no AVA: baixo, médio e alto;
- Risco final: baixo, médio, alto e crítico.

Essa representação facilita a interpretação dos resultados por especialistas da área educacional.

3.9 Funções de Pertinência

As funções de pertinência descrevem matematicamente o grau de pertencimento de um elemento a determinado conjunto fuzzy.

Foram utilizadas funções trapezoidais nas extremidades dos universos de discurso, permitindo representar regiões de certeza elevada, e funções triangulares nas regiões intermediárias, modelando transições graduais entre os diferentes termos linguísticos.

Essa combinação proporciona simplicidade computacional e boa capacidade de representação dos conceitos analisados.

3.10 Sistema de Inferência Mamdani

O sistema de inferência fuzzy utilizado neste trabalho foi baseado no método de Mamdani, um dos modelos mais difundidos na literatura.

O processo de inferência é composto por cinco etapas:

1. Fuzzificação dos valores de entrada;
2. Avaliação das regras de inferência;
3. Aplicação das implicações;
4. Agregação dos consequentes;
5. Defuzzificação.

A defuzzificação foi realizada pelo método do centroide, responsável por converter o conjunto fuzzy resultante em um valor numérico único utilizado para representar o risco final de evasão.

4. DESCRIÇÃO DO DATASET

Foi gerada sinteticamente uma base de dados para o treino da ML, e armazenada no arquivo:

‘base_evasao_academica.csv’

O Conjunto de dados possui 420 registros, sendo 140 registros para cada classe de risco,

1.1.

Variável Alvo

A variável alvo do problema é:

Risco_evasao:

Baixo = Baixo risco de evasão,

Médio = Médio risco de evasão,

Alto = Alto risco de evasão.

1.2. Principais Variáveis:

Variável	Descrição
Frequencia	Percentual de presença nas aulas
Nota_media	Média geral das notas
Atividades_entregues	Atividades entregues no prazo
Acessos_ava	Acessos ao AVA por semana
Reprovas_anteriores	Reprovações no histórico
Situacao_financeira	Instável · regular · estável
Risco_evasao	Variável a predizer

Como principal limitação da base, destaca-se sua natureza sintética: os dados foram gerados com distribuições controladas e perfis bem definidos, o que facilita a separação entre classes, mas não reproduz a variabilidade e o ruído presentes em dados acadêmicos reais. Além disso, variáveis potencialmente relevantes, como histórico socioeconômico, saúde mental e vínculo com o curso, não foram incluídas por estarem fora do escopo do dataset sintético utilizado.

5 ANÁLISE EXPLORATÓRIA DOS DADOS (EDA)

A análise exploratória teve como objetivo identificar padrões, anomalias, e poder discriminativo de cada variável, para efetuar o pré-processamento dos dados.


1.3. Valores Ausentes

Inicialmente foi realizada a verificação de valores ausentes.

Por se tratar de uma base de dados sintética, não encontramos nenhum valor ausente, porém é de suma importância saber que em uma base real, alguns fatores possam ficar ausentes.

1.4. Distribuição de variáveis Numéricas


Fizemos uma análise básica separando todas as variáveis numéricas, e tirando de cada uma sua Média e sua mediana.



De todos os dados apresentados, a maior parte apresenta a média/mediana esperada, mas é interessante que no nosso caso, a maior parte dos estudantes reprovaram ao menos uma vez, com a média de 1.3 reprovações.

1.5. Engajamento x Risco


Foi feita uma avaliação para entender a separação das 3 classes, utilizando o engajamento, definido por frequência, Nota média, e Atividades entregues, todas essas variáveis foram colocadas em comparação em boxplots para dar uma melhor ênfase em suas discriminatividades.



Interpretação :Quanto menor a frequência, nota média, e número de atividades entregues por estudante, maior o risco de evasão, separando bem as 3 classes de risco de evasão, porém nem sempre um estudante com engajamento baixo se encaixa em uma classe de risco maior.

1.6. Correlação de Pearson


Utilizamos a correlação de Pearson para identificar variáveis que possuem multicolinearidade, e caso encontremos uma variável com multicolinearidade grave, a retiramos do nosso treinamento.



Interpretação: Nenhuma variável apresentou uma multicolinearidade absoluta maior que 0.85, portanto podemos manter todas nossas variáveis intactas para o treinamento da ML.

1.7. Frequencia x nota

Frequência e notas são as duas variáveis mais importantes do nosso dataset, por possuírem valores mínimos para aprovação, sendo esses 60% de frequência mínima, e 5.0 de nota para um aluno ser aprovado, logo foi decidido comparar essas variáveis com a classe de risco.



Interpretação: Estudantes com maior nota, e frequência, tendem a estar em classes de risco menor de evasão. É possível que alunos com menor frequência constantemente apresentam maior risco de evasão.

6. PRÉ-PROCESSAMENTO DOS DADOS

Nesta etapa foram realizados tratamentos para preparar os dados para os algoritmos de machine learning. Não foram identificadas inconsistências nos dados, dado o caráter sintético da base. Em relação à variável categórica *Situacao_financeira* (instável, regular, estável), optou-se por não utilizá-la diretamente nos modelos de ML nem no sistema Fuzzy, pois análises exploratórias preliminares indicaram baixo poder discriminativo entre as classes de risco; ela foi mantida no dataset para fins documentais.

6.1 Codificação do Alvo

Para a utilização das classes de risco em código, essas necessitaram ser codificadas, nisso para manter a ordem semântica foram mapeadas manualmente da seguinte forma :

Risco evasao	Mapeamento
baixo	0
medio	1
alto	2

6.2 Normalização

Para a utilização do algoritmo de Naive Bayes, as variáveis foram normalizadas utilizando *StandardScaler*, para ter um z-score estável.

6.3 Divisão

Por se tratar de um dataset sintético, não possuíamos um dataset de teste, então foi decidido separar o dataset total em dois, com uma separação 70/30, 70% dos registros ficaram para o treinamento, enquanto 30% foram separados para testes estratificados. Nessa separação é importante manter a proporção de classes de risco.

Com isso ficaram 294 registros para treino, com cada classe de risco tendo 98 registros, e 126 registros para teste, com cada classe de risco tendo 42 registros.

7. MODELAGEM

Foram utilizados dois modelos de classificação:

- Árvore de Decisão, modelo baseado em particionamento hierárquico cujas regras de divisão guardam similaridade estrutural com as regras de inferência de sistemas Fuzzy
- Naive Bayes Gaussiano, probabilístico por natureza

7.1 Estratégia de Avaliação

Foram definidas 5 métricas de avaliação.

Acurácia = Proporção de predições corretas; para ter uma base de acertos, porém pode ser enganoso com bases desbalanceadas.

Precisão macro = Dos preditos como classe X, quantos realmente são X; para penalizar falso positivos.

Recall macro = Dos que são classe X, quantos o modelo encontrou; para penalizar falso negativos

F1-score macro = Média harmônica entre precisão e recall; A métrica mais equilibrada para

multiclasses.

CV 5-fold = Estima a capacidade de generalização e detecta overfitting.

Dessas métricas, a acurácia foi definida como métrica principal para referência do modelo, por apresentar uma visão geral da performance dos modelos.

7.2 Primeiro Modelo – Árvore de Decisão

A árvore de decisão foi escolhida pela sua boa acurácia vindo de sua simplicidade, além do bônus de ser possível ter uma representação gráfica de suas decisões.

Os dados utilizados pela árvore foram os dados puros, sem passar por normalização.

Nossa árvore de decisão apresentou algumas limitações

Limitação	Valor	Descrição
Max_depth	6	A profundidade máxima que o algoritmo poderá atingir, feito para evitar overfitting
Min_samples_leaf	5	Para cada “folha” da árvore é necessário existir ao menos 5 registros, feita para evitar decisões instáveis.
criterion	gini	
Class_weight	balanced	

Resultado

Acurácia média: 0.8413

F1- macro: 0.8437

CV F1 5-fold : 0.7985

Matriz de confusão:


A confusion matrix showing the relationship between True labels (baixo, medio, alto) and Predicted labels (baixo, medio, alto). The matrix is a 3x3 grid where the color of each cell represents the count of instances. Darker blue indicates a higher count.

	baixo	medio	alto
baixo	35	7	0
medio	7	34	1
alto	0	5	37

Uma grande vantagem do modelo de árvore de decisão, é a possibilidade de visualização de como o modelo funciona, abaixo está a visualização do modelo resultante.

Figure 1 illustrates a hierarchical tree structure for classifying 1000 simulated datasets into 1000 simulated classes. The root node is labeled '1000' and branches into 'True' and 'False' categories. Each node contains information about the number of samples, the number of classes, and the number of features. The 'True' branch leads to a 'True' node, which then branches into 'True' and 'False' categories. The 'False' branch leads to a 'False' node, which then branches into 'True' and 'False' categories. The tree continues to branch down to 1000 simulated classes, each represented by a colored box (purple, green, or orange) containing the class name and its associated parameters.

Importância das variáveis:



No nosso treino foi possível observar que algumas variáveis foram mais importantes para a decisão final do que outras; podemos isolar o top 3: acessos ao AVA, frequência e atividades entregues.

Interpretação

Apesar de ser um modelo simples, pode-se observar que é um modelo bem potente e que facilita bastante a compreensão das decisões.

7.3 Segundo Modelo – Naive Bayes Gaussiano

O segundo modelo escolhido foi o Naive Bayes Gaussiano, probabilístico em sua natureza, porém bastante potente,

Antes de seu treinamento o dataset foi normalizado com StandardScaler.

Diferente do modelo anterior, não foi preciso passar nenhuma limitação.


Resultado:

Acurácia média: 0.9206

F1- macro: 0.9201

CV F1 5-fold : 0.9287

Matriz de confusão:




A matriz exhibe a grande eficácia desse modelo, apresentando apenas falhas em casos de classe de médio risco.

Interpretação:

O modelo Naive Bayes Gaussiano, apesar de ser mais complexo que a árvore de decisão, ainda é um algoritmo bem simples, e probabilístico em sua natureza, os seus resultados foram bem impressionantes.

8. SISTEMA DE INFERÊNCIA FUZZY

Para a utilização do framework Fuzzy precisávamos escolher um modelo, então comparamos as métricas de cada um.



O modelo Naive Bayes Gaussiano apresentou todas as métricas significativamente superiores às da Árvore de Decisão, sendo por isso selecionado como base do pipeline integrado com o sistema Fuzzy (Abordagem B).

O sistema de inferência Fuzzy foi construído com o método de Mamdani, utilizando a biblioteca scikit-

fuzzy. A arquitetura adotada recebe três variáveis de entrada: (1) `prob_evasao_ml` — a probabilidade $P(\text{evasão} = \text{alto})$ gerada pelo Naive Bayes, no intervalo 0–1; (2) frequência — percentual de presença do estudante, de 0% a 100%; e (3) `engajamento_ava` — acessos ao Ambiente Virtual de Aprendizagem por semana, de 0 a 30. A variável de saída, `risco_final`, é um score contínuo de 0 a 100 que o sistema converte em um rótulo linguístico.

Para cada variável de entrada foram definidas funções de pertinência trapezoidais nas extremidades do universo de discurso — capturando a certeza plena nas bordas — e triangular no centro, modelando a transição gradual. A saída possui quatro termos linguísticos: baixo (0–35), médio (25–65), alto (50–82) e crítico (75–100), sendo o quarto termo uma granularidade adicional que distingue casos de emergência imediata dos demais casos de risco elevado — nuance que a classificação discreta do ML não é capaz de expressar.

Foram definidas oito regras no formato SE...ENTÃO, ilustradas na tabela a seguir:

- R1: SE `prob_alta` E `freq_baixa` → CRÍTICO (probabilidade alta + baixa presença = emergência).
- R2: SE `prob_alta` E `eng_baixo` → CRÍTICO (probabilidade alta + sem acesso ao AVA).
- R3: SE `prob_alta` E `freq_media` → ALTO (risco elevado mesmo com frequência mediana).
- R4: SE `prob_media` E `freq_baixa` → ALTO (risco médio agravado por baixa presença).
- R5: SE `prob_media` E `eng_medio` → MÉDIO (engajamento regular atenua o risco moderado).
- R6: SE `prob_media` E `freq_alta` E `eng_medio` → MÉDIO (frequência alta com engajamento médio).
- R7: SE `prob_baixa` E `freq_alta` → BAIXO (ML confiante + alta presença = perfil seguro).
- R8: SE `prob_baixa` E `eng_alto` → BAIXO (ML confiante + muito ativo no AVA = perfil de sucesso).

O processo de inferência seguiu as cinco etapas clássicas do método Mamdani: (1) fuzzificação, convertendo os valores numéricos em graus de pertinência $\mu(x)$; (2) avaliação das regras com operador E = mínimo; (3) implicação, cortando a função de pertinência consequente no nível de ativação; (4) agregação dos consequentes pelo máximo; e (5) defuzzificação pelo método do centroide (center of gravity), obtendo o score final numérico no intervalo 0–100.

O pipeline integrado (Abordagem B) funcionou da seguinte forma: o Naive Bayes recebeu os seis atributos do estudante e devolveu probabilidades calibradas para cada classe; a probabilidade $P(\text{evasão} = \text{alto})$ foi extraída e, junto com frequência e acessos_ava, alimentou o sistema Fuzzy; o Fuzzy retornou um score 0–100 e um rótulo linguístico acionável pelos coordenadores pedagógicos. A análise de coerência revelou concordância de aproximadamente 86% entre as predições do ML e os rótulos gerados pelo Fuzzy, com separação média de cerca de 67 pontos entre os scores dos estudantes de alto risco (≈ 84) e de baixo risco (≈ 17), validando a calibração do sistema.

9. INTEGRAÇÃO E COMPARAÇÃO

A etapa de integração teve como objetivo analisar a complementaridade entre os modelos de Machine Learning e o sistema de inferência fuzzy. Inicialmente foram comparados os resultados obtidos pelos algoritmos Árvore de Decisão e Naive Bayes Gaussiano. O modelo Naive Bayes apresentou desempenho superior em todas as métricas analisadas, alcançando acurácia média de 92,1% e F1-macro de 0,9201, sendo selecionado como componente principal da arquitetura híbrida.

Na abordagem adotada, o modelo de Machine Learning é responsável por estimar a probabilidade de um estudante pertencer à classe de alto risco de evasão. Essa probabilidade, combinada com informações de frequência e engajamento no ambiente virtual de aprendizagem, é utilizada como entrada do sistema fuzzy.

A análise dos resultados revelou concordância aproximada de 86% entre as classificações produzidas pelo modelo probabilístico e pelo sistema fuzzy. Esse elevado nível de concordância indica que ambos

os métodos capturam padrões semelhantes presentes nos dados, reforçando a consistência da solução proposta.

Por outro lado, aproximadamente 14% dos casos apresentaram divergências entre os dois sistemas. Essas divergências ocorreram principalmente em situações limítrofes, nas quais estudantes possuíam probabilidade moderada de evasão segundo o modelo estatístico, mas apresentavam indicadores recentes de frequência ou engajamento significativamente diferentes.

Nesses casos, o sistema fuzzy demonstrou capacidade de incorporar informações contextuais adicionais por meio das regras linguísticas definidas, refinando a interpretação produzida pelo modelo de Machine Learning. Dessa forma, as divergências não devem ser interpretadas como erros, mas como evidências da complementaridade entre as abordagens.

10. RESULTADOS E DISCUSSÃO

Os resultados obtidos demonstraram que ambos os modelos de Machine Learning apresentaram desempenho satisfatório para o problema proposto. A Árvore de Decisão alcançou acurácia média de 84,13%, enquanto o Naive Bayes Gaussiano obteve acurácia média de 92,06%, tornando-se o modelo mais adequado para integração com o sistema fuzzy.

A análise das matrizes de confusão mostrou que os erros de classificação ocorreram predominantemente entre as classes de risco médio e alto, comportamento esperado devido à proximidade entre esses perfis. Ainda assim, a taxa de acerto observada demonstra que as variáveis utilizadas possuem capacidade discriminativa suficiente para separar adequadamente os diferentes níveis de risco.

A análise de importância das variáveis revelou que frequência, acessos ao ambiente virtual e atividades entregues exerceram influência significativa nas decisões dos modelos. Esse resultado está alinhado com a literatura educacional, que frequentemente associa engajamento acadêmico à permanência dos estudantes nos cursos.

No sistema fuzzy, observou-se clara separação entre os perfis de baixo e alto risco. Os estudantes classificados como alto risco apresentaram score médio próximo de 84 pontos, enquanto os estudantes de baixo risco apresentaram score médio próximo de 17 pontos. Essa diferença evidencia a eficácia das funções de pertinência e das regras de inferência utilizadas.

A integração entre Machine Learning e Lógica Fuzzy demonstrou ser uma estratégia eficiente para combinar capacidade preditiva e interpretabilidade. Enquanto o modelo estatístico oferece previsões quantitativas consistentes, o sistema fuzzy traduz essas previsões para uma linguagem mais compreensível por coordenadores e especialistas educacionais.

Entretanto, algumas limitações devem ser consideradas. O uso de dados sintéticos pode não reproduzir integralmente a complexidade de cenários reais. Além disso, o sistema fuzzy utiliza apenas parte das variáveis disponíveis na base de dados, o que pode limitar sua capacidade de representar situações mais complexas. Apesar dessas restrições, os resultados obtidos indicam que a abordagem híbrida proposta apresenta potencial para aplicação em contextos educacionais reais, desde que validada em bases institucionais adequadamente anonimizadas e em conformidade com a LGPD.

Para ilustrar o comportamento do sistema, foram aplicados três casos de teste representativos. Caso 1 (perfil de baixo risco): estudante com frequência de 88%, nota média de 8,2, 85 atividades entregues e 14 acessos semanais ao AVA — o Naive Bayes atribuiu probabilidade de evasão alta de 4%, e o sistema Fuzzy gerou score de 12, rótulo BAIXO. Caso 2 (perfil de médio risco): frequência de 62%, nota média de 5,1, 52 atividades entregues e 6 acessos semanais — probabilidade de 51%, score Fuzzy

de 48, rótulo MÉDIO. Caso 3 (perfil de alto risco): frequência de 38%, nota média de 3,4, 30 atividades entregues e 2 acessos semanais — probabilidade de 93%, score Fuzzy de 87, rótulo CRÍTICO. Esses casos confirmam a coerência entre os dois sistemas e demonstram a capacidade do pipeline de distinguir com clareza os diferentes níveis de risco.

11. LIMITAÇÕES DO TRABALHO

O presente trabalho apresenta algumas limitações que devem ser consideradas na interpretação dos resultados. A principal limitação é o uso de uma base de dados sintética, que embora permita exemplificar a utilização dos algoritmos sem conflito com a LGPD, não reflete necessariamente a complexidade e a variabilidade presentes em dados acadêmicos reais.

Além disso, o número reduzido de registros (420 amostras) limita a capacidade de generalização dos modelos, especialmente em cenários com distribuições de classe diferentes das utilizadas no treino. As variáveis utilizadas também são limitadas, e fatores como histórico socioeconômico detalhado, dados de saúde mental ou vínculo com o curso não foram considerados.

O sistema Fuzzy emprega apenas 3 das 6 variáveis disponíveis no dataset — `prob_evasao_ml`, frequência e `acessos_ava` — deixando `nota_media` e `situacao_financeira` fora do motor de inferência. Incluir essas variáveis poderia enriquecer a saída e reduzir discrepâncias nos casos limítrofes. Adicionalmente, as funções de pertinência e as 8 regras foram definidas por heurística pedagógica sem otimização automática, o que significa que em produção deveriam ser calibradas com especialistas da área e validadas com dados reais.

Por fim, a base sintética gerada possui distribuições controladas com perfis bem definidos entre as classes, o que pode superestimar o desempenho real dos modelos em dados reais, onde sazonalidade, eventos externos e heterogeneidade do perfil discente introduzem maior ruído.

12. POSSÍVEIS MELHORIAS

Como trabalhos futuros, poderiam ser realizados:

Expansão do conjunto de variáveis preditoras, incluindo dados socioeconômicos, histórico de participação em atividades extracurriculares e indicadores de saúde mental.

Incorporação de ANFIS (Adaptive Neuro-Fuzzy Inference System) para calibrar automaticamente as funções de pertinência a partir dos dados, eliminando a dependência de definições heurísticas e tornando o sistema adaptável a novos perfis discentes.

Inclusão das variáveis `nota_media` e `situacao_financeira` no motor Fuzzy, ampliando de 3 para 5 as entradas do sistema e potencializando a granularidade do score de risco gerado.

Desenvolvimento de um dashboard interativo em Streamlit para que coordenadores e pedagogos possam consultar em tempo real os estudantes com maior risco (crítico e alto), visualizar o score Fuzzy e acionar intervenções preventivas de forma ágil.

Adição de variáveis temporais ao pipeline, como tendência de queda de frequência nos últimos períodos, que são preditores mais fortes de evasão iminente do que valores pontuais, além do uso de base real de instituição de ensino superior parceira em conformidade com a LGPD.

13. CONCLUSÃO

Este trabalho demonstrou com sucesso a viabilidade de um sistema híbrido de classificação de risco de evasão acadêmica combinando técnicas de Machine Learning supervisionado com inferência Fuzzy. Os dois modelos avaliados apresentaram desempenhos expressivos: a Árvore de Decisão atingiu acurácia média de 84,1% com F1-macro de 0,8437, enquanto o Naive Bayes Gaussiano alcançou acurácia de 92,1% com F1-macro de 0,9201, sendo este selecionado como base do pipeline integrado com Fuzzy.

O sistema Fuzzy Mamdani implementado com 3 variáveis de entrada (prob_evasao_ml, frequência, engajamento_ava), 8 regras linguísticas e 4 termos de saída (baixo, médio, alto e crítico) demonstrou eficácia na segregação dos perfis de risco. A separação média de aproximadamente 67 pontos entre os scores de estudantes de alto risco ($\approx 84/100$) e de baixo risco ($\approx 17/100$) válida a calibração das funções de pertinência e das regras adotadas. A concordância de $\approx 86\%$ entre as predições do ML e os rótulos gerados pelo Fuzzy demonstra a complementaridade dos dois sistemas, sendo os $\approx 14\%$ divergentes informativos: indicam casos em que o contexto atual do estudante (frequência e engajamento recentes) diverge do padrão histórico capturado pelo ML.

Os conceitos da disciplina aplicados neste trabalho incluem: aprendizado supervisionado, classificação multiclasse, Teorema de Bayes, impureza de Gini, validação cruzada estratégica, conjuntos fuzzy (Zadeh, 1965), variáveis linguísticas, fuzzificação, inferência Mamdani e defuzzificação por centroide. Conclui-se que o objetivo principal do trabalho foi plenamente atingido: foi desenvolvido um sistema funcional e interpretavelmente rico de predição de risco de evasão acadêmica, demonstrando a importância e utilidade dos modelos de inferência Fuzzy integrados a pipelines de Machine Learning.

14. BIBLIOTECAS UTILIZADAS

As seguintes bibliotecas Python foram utilizadas no desenvolvimento deste trabalho:

pandas – Manipulação, análise e exportação de dados tabulares (leitura do CSV, geração do DataFrame de resultados da integração).

numpy – Operações numéricas vetorizadas e geração dos universos de discurso para o sistema Fuzzy.

scikit-learn – Implementação dos modelos de Machine Learning (DecisionTreeClassifier e GaussianNB), divisão estratégica com train_test_split, validação cruzada com StratifiedKFold e métricas de avaliação (accuracy_score, classification_report, ConfusionMatrixDisplay).

scikit-fuzzy – Construção do sistema Fuzzy Mamdani: funções de pertinência (trapmf, trimf), cálculo de graus de pertinência com interp_membership e defuzzificação por centroide com defuzz.

matplotlib – Geração de todas as visualizações: histogramas, gráfico da Árvore de Decisão (plot_tree), gráficos de importância de features, funções de pertinência, superfície de controle 3D e gráfico de defuzzificação.

seaborn – Visualização avançada com tema padronizado: boxplots de separabilidade por classe, heatmap de correlação de Pearson e análise gráfica da integração ML+Fuzzy (scatter, boxplot, histograma).

REFERÊNCIAS

RUSSELL, Stuart; NORVIG, Peter. Inteligência Artificial. 3. ed. Elsevier, 2013.

ZADEH, Lotfi A. Fuzzy Sets. Information and Control, v. 8, n. 3, p. 338–353, 1965.

SCIKIT-LEARN. User Guide. https://scikit-learn.org/stable/user_guide.html. Acesso: jun. 2026.

SCIKIT-FUZZY. Documentation. <https://pythonhosted.org/scikit-fuzzy/>. Acesso: jun. 2026.

MALVEZZI, William. Slides de IA: Lógica Fuzzy e Machine Learning. Material interno, 2026.